

Министерство образования Республики Беларусь

Учреждение образования

“БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ”

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №3

по курсу “Модели решения задач в
интеллектуальных системах”

Вариант 5

Выполнил:
студент гр. 221701

Телица И. Д.

Проверил:

Ивашенко В. П.

Минск
2025

Тема: Применение нейронных сетей для прогнозирования числовых последовательностей.

Цель: Ознакомиться, проанализировать и получить навыки реализации модели рекуррентной сети для задачи прогнозирования.

Задание: Реализовать модель рекуррентной сети с цепью нейросетевых моделей долгой кратковременной памяти (LSTM) с функцией активации Leaky ReLU на скрытом слое

Постановка задачи:

В данной лабораторной работе требуется разработать и исследовать модель рекуррентной нейронной сети архитектуры LSTM. Необходимо реализовать механизмы гейтов (фильтров), позволяющих эффективно сохранять информацию на длительных интервалах и решать проблему затухающих градиентов. Обучение сети проводится на некотором наборе числовых последовательностей (экспоненциальная, рекуррентная, степенная и периодическая).

Описание реализации

Программа реализована на языке Python с использованием библиотеки NumPy. Система разделена на модули:

model.py — содержит класс LSTMModel, реализующий гейты (Forget, Input, Output), состояние ячейки (Cell state) и алгоритм обратного распространения ошибки во времени (BPTT).

utils.py — содержит функции генерации данных и класс Scaler для нормализации.

main.py — основной скрипт управления обучением и тестированием.

Описание модели:

LSTM-блок управляет потоком информации с помощью трех фильтров:
Forget Gate: Решает, какую информацию из памяти ячейки следует стереть. Использует сигмоидальную активацию.

Input Gate: Решает, какие новые данные записать в память. Для формирования кандидата в память используется Leaky ReLU.

Output Gate: Формирует выходной сигнал скрытого слоя на основе текущего состояния памяти. Согласно заданию, на этом этапе также применена функция Leaky ReLU.

Архитектура сети:

Рецепторный слой: Принимает вектор значений длиной in_size (скользящее окно).

Скрытый слой: LSTM-ячейка с настраиваемым количеством нейронов (hidden_size).

Выходной слой: Линейный эффектор, формирующий итоговый числовой прогноз.

Описание обучающих и тестовых последовательностей:

Для обучения и тестирования модели используются следующие последовательности, генерируемые программно, количество элементов в выборке регулируется переменной `length` передаваемой в функцию генерации выборки:

1. Геометрическая прогрессия:

- Формула: $x[i] = 2^i$.
- Пример : 1, 2, 4, 8, 16, 32, 64, 128, 256, 512...

2. Числа Фибоначчи:

- Формула: $x[i] = x[i-1] + x[i-2]$.
- Пример: 1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144...

3. Степенная функция:

- Формула: $x[i] = i^2$.
- Пример: 1, 4, 9, 16, 25, 36, 49, 64, 81, 100, 121, 144...

4. Периодический ряд (Sin):

- Формула: $x[i] = 10 * \sin(0.5 * i)$.
- Пример: 0, 4.79, 8.41, 9.97, 9.09, 5.98, 1.41, -3.51, -7.57, -9.59...

Тестирование

Для оценки корректности работы сети последовательно вычисляли несколько прогнозных значений с помощью метода скользящего окна, сохраняя состояние контекстных нейронов.

На рисунке 1 представлено тестирование сети для геометрической прогрессии.

```
=====
ЗАДАЧА: Геометрическая прогрессия
ГИПЕРПАРАМЕТРЫ:
- Общая длина последовательности: 35
- Размер окна (in_size): 3
- Скрытых нейронов (hidden): 32
- Коэффициент обучения (lr): 0.02
- Количество эпох: 8000
- Коэффициент Leaky ReLU (alpha): 0.02
=====

ОБУЧАЮЩАЯ ВЫБОРКА (первые 5 образов):
Вход (X) | Цель (y)
-----|-----
[1, 2, 4] | 8
[2, 4, 8] | 16
[4, 8, 16] | 32
[8, 16, 32] | 64
[16, 32, 64] | 128

Обучение...

РЕЗУЛЬТАТЫ ТЕСТИРОВАНИЯ:
Входные значения | Ожидаемо | Предсказано (float)
-----|-----|-----
[1, 2, 4] | [8] | 8.3756
[131072, 262144, 524288] | [1048576] | 1063651.9390
[8589934585, 17179869169, 34359738337] | [68719476736] | 71712361832.5580
=====
```

Рис.1 . Вывод тестирования сети с геометрической прогрессией

На рисунке 2 представлено тестирование сети для последовательности чисел Фибоначчи.

```
=====
ЗАДАЧА: Числа Фибоначчи
ГИПЕРПАРАМЕТРЫ:
- Общая длина последовательности: 35
- Размер окна (in_size): 3
- Скрытых нейронов (hidden): 32
- Коэффициент обучения (lr): 0.02
- Количество эпох: 8000
- Коэффициент Leaky ReLU (alpha): 0.02
=====

ОБУЧАЮЩАЯ ВЫБОРКА (первые 5 образов):
Вход (X) | Цель (y)
-----|-----
[1, 1, 2] | 3
[1, 2, 3] | 5
[2, 3, 5] | 8
[3, 5, 8] | 13
[5, 8, 13] | 21

Обучение...

РЕЗУЛЬТАТЫ ТЕСТИРОВАНИЯ:
Входные значения | Ожидаемо | Предсказано (float)
-----|-----|-----
[1, 1, 2] | [3] | 3.2649
[2584, 4181, 6765] | [10946] | 11032.5895
[5702887, 9227465, 14930352] | [24157817] | 24845421.7872
=====
```

Рис.2 . Вывод тестирования сети с последовательностью чисел Фибоначчи.

На рисунке 3 представлено тестирование сети для последовательности, заданной степенной функцией.

```
=====
ЗАДАЧА: Степенная функция (x^2)
ГИПЕРПАРАМЕТРЫ:
- Общая длина последовательности: 35
- Размер окна (in_size): 3
- Скрытых нейронов (hidden): 24
- Коэффициент обучения (lr): 0.01
- Количество эпох: 6000
- Коэффициент Leaky ReLU (alpha): 0.02
=====

ОБУЧАЮЩАЯ ВЫБОРКА (первые 5 образов):
Вход (X) | Цель (y)
-----|-----
[1, 4, 9] | 16
[4, 9, 16] | 25
[9, 16, 25] | 36
[16, 25, 36] | 49
[25, 36, 49] | 64

Обучение...

РЕЗУЛЬТАТЫ ТЕСТИРОВАНИЯ:
Входные значения | Ожидаемо | Предсказано (float)
-----|-----|-----
[1, 4, 9] | [16] | 27.9101
[324, 361, 400] | [441] | 443.7540
[1156, 1225, 1296] | [1369] | 1378.4438
=====
```

Рис.3 . Вывод тестирования сети с последовательностью степенной функции

На рисунке 4 представлено тестирование сети для последовательности, заданной периодической функцией.

```
=====
ЗАДАЧА: Периодический ряд (Sin)
ГИПЕРПАРАМЕТРЫ:
- Общая длина последовательности: 35
- Размер окна (in_size): 3
- Скрытых нейронов (hidden): 24
- Коэффициент обучения (lr): 0.01
- Количество эпох: 6000
- Коэффициент Leaky ReLU (alpha): 0.02
=====

ОБУЧАЮЩАЯ ВЫБОРКА (первые 5 образов):
Вход (X) | Цель (y)
-----|-----
[-0.0000, 4.7943, 8.4147] | 9.9749
[4.7943, 8.4147, 9.9749] | 9.0930
[8.4147, 9.9749, 9.0930] | 5.9847
[9.9749, 9.0930, 5.9847] | 1.4112
[9.0930, 5.9847, 1.4112] | -3.5078

Обучение...

РЕЗУЛЬТАТЫ ТЕСТИРОВАНИЯ:
Входные значения | Ожидаемо | Предсказано (float)
-----|-----|-----
[-0.0, 4.7943, 8.4147] | [9.9749] | 10.0037
[7.9849, 4.1212, -0.7515] | [-5.4402] | -5.4835
[-7.1179, -9.614, -9.7563] | [-7.5099] | -7.4313
=====
```

Рис.4 . Вывод тестирования сети со периодической функцией

Графики

График зависимости среднего количества итераций обучения от максимально допустимой ошибки(рис. 5)

Используется последовательность степенной функции

Параметры сети:

α (коэффициент обучения): 0.01

win (размер окна): 3

hid (количество нейронов скрытого слоя): 16

eff (количество эффекторов): 1




Рис. 5. График зависимости среднего количества итераций обучения от максимально допустимой ошибки

График зависимости среднего количества итераций обучения от коэффициента обучения(рис. 6)

Используется последовательность степенной функции

Параметры сети:

err (допустимая ошибка): 0.0005

win (размер окна): 3

hid (количество нейронов скрытого слоя): 16

eff (количество эффекторов): 1




Рис. 6. График зависимости среднего количества итераций обучения от коэффициента обучения

График зависимости количества итераций обучения от размера скользящего окна(рис. 7)

Используется последовательность степенной функции

Параметры сети:

α (коэффициент обучения): 0.01

err (допустимая ошибка): 0.0005

hid (количество нейронов скрытого слоя): 16

eff (количество эффекторов): 1




Рис. 7. График зависимости количества итераций обучения от размера скользящего окна

График зависимости средней абсолютной процентной от количества нейронов на скрытом слое(рис. 8)

Используется последовательность степенной функции

Параметры сети:

a (коэффициент обучения): 0.01

win (размер окна): 3

eff (количество эффекторов): 1

st (количество запусков): 1 (для каждой вариации hid)

hid (варианты скрытого слоя): 8, 16, 32




Рис. 8. График зависимости средней абсолютной процентной ошибки от количества итераций от количества нейронов на скрытом слое

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|Y_i - \hat{Y}_i|}{Y_i} * 100$$

Где:

- n – количество наблюдений
- Y_i – фактическое значение
- $\hat{Y}_i$ – прогнозируемое значение

Ответы на контрольные вопросы

1. Как влияет размер скользящего окна на достигаемую ошибку?

Из графика на рисунке 7 видно, что при увеличении размера скользящего окна возрастает и число необходимых итераций.

2. Как влияет количество контекстных нейронов на достигаемую ошибку?

Рост числа контекстных нейронов расширяет объём сохраняемой информации о прошлых состояниях сети, что приводит к уменьшению ошибки.

3. Как влияет количество нейронов скрытого слоя на достигаемую ошибку?

Согласно графику на рисунке 8, с увеличением числа нейронов в скрытом слое средняя процентная ошибка снижается.

4. Как влияет зануление контекстных нейронов на результат обучения?

Обнуление контекстных нейронов приводит к увеличению ошибки, поскольку сеть утрачивает информацию о предыдущих шагах последовательности.

5. Какие последовательности прогнозируются точнее всего?

Наибольшая точность достигается при прогнозировании коротких последовательностей с плавными изменениями.

6. Какие последовательности прогнозируются наименее точно?

Наименьшая точность наблюдается при прогнозировании случайных, резко изменяющихся и длинных последовательностей.

7. Как отображена последовательность на область выходных значений эффекторов?

Последовательность передаётся через выходные нейроны сети в нормализованной форме, при этом каждый её элемент соответствует определённому значению выходных нейронов.

8. Как зависит ошибка от количества итераций обучения?

С увеличением числа итераций обучения ошибка снижается и затем достигает стабильного минимального значения.

9. Сколько образов в обучающей выборке, если при окне размера p прогнозируется один элемент, а последовательность имеет q элементов?

Количество образов в обучающей выборке равно $q - p$.

Вывод: В ходе лабораторной работы была успешно реализована и исследована модель рекуррентной нейронной сети. Основной целью работы было изучение способности сети прогнозировать значения временных рядов.

Результаты тестирования показали высокую эффективность разработанной модели: сеть продемонстрировала способность корректно продолжать заданные числовые последовательности.

Список использованных источников

1. Формальные модели обработки информации и параллельные модели решения задач. Практикум: учебно-методическое пособие / В.П.Ивашенко. – Минск: БГУИР, 2020.
2. Методические указания к лабораторной работе.